

Estudio de los movimientos gimnásticos de Crossfit

Jorge Marqués García

Resumen

En este trabajo se presenta una revisión sistemática del uso de sensores inerciales (IMUs) en el análisis biomecánico de cuatro movimientos gimnásticos fundamentales del CrossFit: pull-up, kipping pull-up, butterfly pull-up y muscle-up. Usando un macro PICOS se recopila y analiza literatura reciente que emplea IMUs para estudiar variables como aceleración lineal, angular y centro de masas, priorizando estudios con participantes sanos y experiencia intermedia. También se examinan configuraciones de sensores, técnicas de procesamiento y métricas de precisión empleadas. Los resultados muestran una alta variabilidad metodológica, pero evidencian el potencial de estas tecnologías para evaluar y mejorar el rendimiento deportivo en entornos no controlados.

Introducción

En los últimos años, el CrossFit ha experimentado un notable crecimiento en popularidad, atrayendo a millones de practicantes en todo el mundo, de hecho, se estima que en 2023 había más de cuatro millones de participantes en todo el mundo [1]. Este deporte se caracteriza por la ejecución de movimientos funcionales de alta intensidad que combinan ejercicios de acondicionamiento metabólico, gimnasia, levantamiento olímpico y movimientos de powerlifting. La gran cantidad y variedad de ejercicios que incorpora esta modalidad deportiva la convierte en una buena fuente de estudio para análisis biomecánicos, tanto por su interés de prevención de lesiones como las dificultades que plantea el análisis de tantos movimientos. Sin embargo, este trabajo únicamente se centra en cuatro de los movimientos gimnásticos básicos de crossfit, *pull-up*, *kiping pull-up*, *butterfly-pull up* y *muscle up*. Que son movimientos de barra similares a los que realizan los gimnastas olímpicos en sus ejercicios, que incluyen el uso de muchos grupos musculares y momentos de inercia conjuntamente.

Paralelamente, los avances tecnológicos han abierto nuevas posibilidades para el análisis biomecánico y la evaluación del movimiento deportivo. Herramientas como sensores inerciales y cámaras 3D han demostrado ser prometedoras para analizar movimientos específicos del deporte y evaluar el

equilibrio postural de los atletas [2]. Estas tecnologías no solo permiten una recopilación eficiente de datos en entornos no controlados, sino que también ofrecen una alternativa más accesible frente a métodos tradicionales costosos y limitados.

En este contexto, este trabajo busca realizar una revisión bibliográfica sobre el uso de tecnologías emergentes en el análisis biomecánico del CrossFit y otros deportes relacionados. Para ello, se investigan diferentes métodos de sensorización, población participante, variables extraídas del movimiento y procesamiento de dichas variables.

Metodología

A la hora de realizar una revisión exhaustiva sobre la literatura científica actual sobre análisis biomecánico de movimientos gimnásticos en Crossfit, se ha realizado un macro PICOS (Población, Intervención, Comparación, Resultados, Contexto) con el que contextualizar, buscar y filtrar bibliografía. Para ello se ha utilizado la herramienta de inteligencia artificial ChatGPT.

Gracias a eso, la selección de los distintos artículos se ha basado en participantes con nivel de principiante o intermedio que no hayan sufrido problemas de salud de cualquier tipo en al menos los tres últimos meses. Se han descartado toda la literatura que no utilizara sensores inerciales IMUs dentro de su estudio, o en los que los movimientos analizados hayan sido únicamente estáticos.

Además, se ha priorizado sobre las métricas de aceleración lineal, aceleración angular y movimiento del centro de masas frente ángulos, presión o velocidad. Atendiendo especial atención a aquellas técnicas capaces de comparar resultados con otros métodos de recolección de datos como cámaras Mocap.

Tras identificar los estudios pertinentes, se extrae la población de interés, recopilación de datos y posicionamiento de los sensores, procesamiento y comparación de resultados.

Resultados

Participantes

La estructura de participantes dentro de los estudios recopilados puede ser muy variada, con variaciones de edades muy amplias, comprendidas desde la infancia [3], hasta la edad adulta [1]. Sin embargo, es identificativo de todos los estudios que todos los participantes de estudio estén en condiciones similares de edad, peso, altura, y frecuencia de entrenamiento. Esta información es recalcada en cada uno de los artículos y frecuentemente desglosada en forma de tabla. [Fig. 1].

Table 1. Mean \pm SD of anthropometric and demographic data features of CrossFit Athletes.

Variables	Athletes (n = 42)	Male (n = 18)	Female (n = 24)
Age: mean (minimum-maximum)	32.5 (25-42)	31.3 (25-37)	34.1 (26-42)
Height (cm): mean (minimum-maximum)	174.9 (161-189)	181.3 (175-189)	166.5 (161-175)
Body mass (kg): mean (minimum-maximum)	71.7 (51-86)	80.75 (74-86)	59.6 (51-69)
Shoe size: mean (minimum-maximum)	42 (37-45)	43 (41-45)	39 (37-42)

Fig. 1. Desglose en forma de tabla de los sujetos de estudio en [1]. incluyendo media y número de participantes.

Sensores: posicionamiento y configuración

Tal y como se ha explicado en la metodología, se han rechazado toda literatura que no incluyera como alguno de sus métodos de estudio el uso de IMUs.

El abanico de IMUs utilizados es muy variado en función del movimiento llevado a estudio, utilizando MPU6500 [4], Shimmer3 [5], Aidmed One [6] y otros. Sin embargo, el posicionamiento de los sensores es un parámetro crucial en los estudios y a los que hay que prestar especial atención.

Tal y como se explica en [7,8], a pesar de que el posicionamiento ideal supone un objeto de estudio importante para cada aplicación, existen ciertas posiciones comunes dentro del cuerpo humano que resultan muy recomendables a la hora de realizar reconocimiento de la actividad humana (HAR por sus siglas en inglés). La figura 2 muestra un ejemplo de posicionamientos recomendables para los movimientos en los que se centra este trabajo según [3].

En lo relativo a la configuración de los sensores, la literatura recogida para estos movimientos gimnásticos coincide en bastante medida en realizar medidas por encima de los 100 Hz de frecuencia de sampleo [9-11] con algunas excepciones de 50Hz [4,6]. A pesar de ello, cabe destacar que algunos

autores remarcan la ausencia de estandarización de este parámetro en la comunidad científica [12]

Existe mayor estandarización para identificar el rango de medida de los movimientos desde los 4 a los 16 g de aceleración. [9].




Fig. 2. Posición de IMUs (a) Espalda alta, (b) Espalda baja, (c) Muñecas, (d) Tobillos

Variables extraídas y técnicas de procesamiento

En referencia a las variables extraídas de los sensores para su procesamiento, las principales métricas utilizadas en monitorización de movimientos similares a los de estudio, incluyendo su precisión en la predicción de movimientos.

Principalmente, se usan las medidas de aceleración directas de los acelerómetros y giróscopos en los tres ejes cartesianos, aunque también se usan variables de mayor complejidad de procesamiento tales como la aceleración del centro de masas, vectores de magnitud, tanto de aceleración lineal como angular (AVM y AnVM) (1)

$$AVM[i] = \sqrt{(a_x[i])^2 + (a_y[i])^2 + (a_z[i])^2} \quad (1)$$

Otro tipo de variables menos utilizadas son vectores de velocidad pico concéntrica (VPC), velocidad media concéntrica (VMC), velocidad pico excéntrica (VPE), velocidad media excéntrica (VME), velocidad media de propulsión (VMP), velocidad vertical de pico (BW) [11,13].

Finalmente, en lo referido a la precisión de reconocimiento de los distintos modelos, existen una gran cantidad de métricas existentes. Sin embargo, la elección de las métricas no resulta arbitraria, sino que

depende de el enfoque elegido por el estudio. Métricas como el *recall*, F1 score, error porcentual absoluto medio (MAPE por sus siglas en inglés) o el ratio de falsos positivos (FPR) aparecen repetidamente en [4-7], estudios que llevan a cabo procedimientos de deep learning en sus procesos de HAR.

Por otro lado, [1-3,9-12] utilizan otro tipo de variables para medir la precisión de sus estudios. Se pueden encontrar variables como estadísticas del tamaño del efecto de Cohen, correlación de Pearson o coeficientes de variación. Sin embargo, cabe destacar que estos coeficientes de análisis estadístico requieren de una cantidad de datos suficientemente amplia para poder considerar el estudio como paramétrico, lo que no siempre se cumple.

Estos factores son determinantes a la hora de medir la precisión de los estudios, y explican por qué implementaciones de modelos de deep learning en HAR se mantienen en mayores valores de precisión (~98%) respecto a los análisis estadísticos en los que podemos encontrar variaciones desde el 60% hasta el 95%.

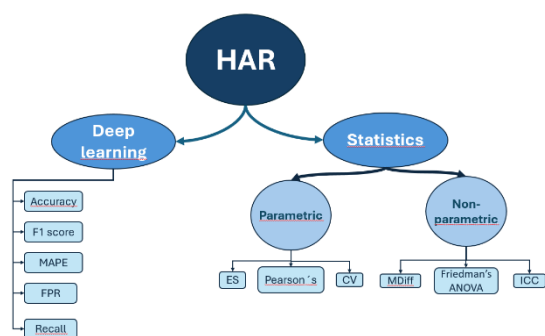


Fig. 3. Diagrama de variables para el análisis de precisión en función de la metodología. ES : Cohen effect size, CV: coefficient deviation, MDiff: means difference, ICC: intra-class correlation coefficient, MAPE: mean absolute percentage error, FPR: false-positive ratio.

Conclusiones

El uso de sensores inerciales (IMUs) en el análisis de movimientos gimnásticos de CrossFit ha demostrado ser una herramienta prometedora para evaluar la técnica y el rendimiento en entornos reales. La capacidad de capturar datos en tiempo real y fuera del laboratorio permite una aproximación más funcional al estudio de movimientos complejos como el pull-up o el muscle-up, aportando valor tanto en el ámbito deportivo como en el clínico.

A la vista de los resultados estudiados, y siguiendo la Tabla 1. comparativa, salta a la vista la falta de homogeneidad metodológica en los estudios. Empezando por la muestra de sujetos para el estudio, a pesar de que, sí que existe una separación en función del nivel de los participantes y el sexo, no hay una consideración clara acerca de las edades de los participantes, encontrando diferencias de hasta 30 años entre estudios. Dando a pensar que la elección de muestra es más por disponibilidad del estudio que por elección.

En cuanto a la ubicación de los sensores, tal y como se ha explicado en el apartado anterior, es difícil realizar una estandarización de posicionamiento y cada movimiento puede requerir un estudio específico. Sin embargo, existen ciertas coincidencias en lugares de posicionamiento dentro del cuerpo humano, a saber: muñeca, tobillo, espalda alta y espalda baja. [12]. Gracias a la bibliografía y pensando en las disponibilidades del trabajo futuro, serán estas posiciones las elegidas para los futuros estudios.

En lo que concierne a la configuración de los IMUs, es importante tener una visión crítica de la literatura. La utilización de IMUs comerciales es unánime a toda la literatura, por lo que la elección de la frecuencia de sampleo muchas veces no es un parámetro sencillo de elegir por el usuario, por lo que se usan las configuraciones por defecto del sensor. Es por eso que, en el trabajo, se empezarán usando frecuencias cercanas a las encontradas por la literatura, pero no se descarta el llegar a frecuencias mucho más bajas, entre 10 Hz y 20 Hz.

Los movimientos llevados a estudio también son determinantes a la hora de la elección de las variables de análisis extraídas por los sensores. Variables como VPC, VPE o BW no parecen elecciones demasiado sensatas para movimientos muy dinámicos como los que se quieren estudiar, tal y como se puede ver en [11,13]. Variables como la aceleración vectorial y en módulo parecen se postulan con mayor probabilidad de éxito en otras referencias [3,5,12].

Sin duda, el mayor punto de inflexión en el trabajo es la metodología elegida para el procesamiento de datos. A la vista de los resultados expresados al final del apartado anterior, parece que el uso de redes neuronales o metodología deep learning obtiene tasas de acierto que se mantienen considerablemente más estables en valores altos (por encima del 90%) frente a los análisis estadísticos, con variaciones de hasta el 30% dentro del mismo estudio). Este factor es debido a que los análisis estadísticos tiene mucha

más dependencia con la muestra de datos tomada, por lo que un número insuficiente de datos o correlaciones en los mismos puede originar las desviaciones que se observan.

Por lo tanto, a la vista de la bibliografía encontrada y gracias a la disponibilidad de recursos para este trabajo, se hará un estudio usando una muestra lo más equitativa en cuanto a niveles y sexos dentro de las disponibilidades. La colocación de los IMUs será en muñecas, brazos y espalda, configurados inicialmente a frecuencias de 100Hz, aunque luego se hará un procesamiento de datos para bajar lo máximo posible dicha frecuencia sin perder rigurosidad en los datos. Dadas las características de los movimientos elegidos, se utilizarán aceleraciones en forma vectorial y modular en cada posición, y se usará una estructura de deep learning para el procesamiento en tiempo real de los datos, gracias a las características que nos ofrece el módulo NANO BLE 33 elegido.

REFERENCIAS

- [1]. Brognara, L., Mazzotti, A., Rossi, F., Lamia, F., Artioli, E., Faldini, C., & Traina, F. (2023). Using Wearable Inertial Sensors to Monitor Effectiveness of Different Types of Customized Orthoses during CrossFit® Training. *Sensors*, 23(3). <https://doi.org/10.3390/s23031636>
- [2]. Izzo, R., Biancalana, V., Ubertini, S., Cejudo, A., Cruciani, A., Varde'i, H., & Crudelini, E. (2024). Inertial analysis of acceleration, deceleration, and angular speed in the technical of the front tucked somersault in female artistic gymnastics. *Journal of Physical Education and Sport*, 24(6), 1336–1348. <https://doi.org/10.7752/jpes.2024.06152>
- [3]. Campbell, R. A., Bradshaw, E. J., Ball, N., Hunter, A., & Spratford, W. (2021). Inertial measurement units are 'all g': Inter-trial reliability when assessing upper and lower body impact loading in artistic gymnastics. *International Journal of Sports Science and Coaching*, 16(2), 380–390. <https://doi.org/10.1177/1747954120970310>
- [4]. Wang, W., Lian, C., Zhao, Y., & Zhan, Z. (2024). Sensor-Based Gymnastics Action Recognition Using Time-Series Images and a Lightweight Feature Fusion Network. *IEEE Sensors Journal*. <https://doi.org/10.1109/JSEN.2024.3492004>
- [5]. Tian, J., Zhou, P., Sun, F., Wang, T., & Zhang, H. (2021, July 20). Wearable IMU-based Gym Exercise Recognition Using Data Fusion Methods. *ACM International Conference Proceeding Series*. <https://doi.org/10.1145/3469678.3469705>
- [6]. Czekaj, Ł., Kowalewski, M., Domaszewicz, J., Kitłowski, R., Szwoch, M., & Duch, W. (2024). Real-Time Sensor-Based Human Activity Recognition for eFitness and eHealth Platforms. *Sensors*, 24(12). <https://doi.org/10.3390/s24123891>
- [7]. Spilz, A., & Munz, M. (2023). Automatic Assessment of Functional Movement Screening Exercises with Deep Learning Architectures. *Sensors*, 23(1). <https://doi.org/10.3390/s23010005>
- [8]. Reining, C., Niemann, F., Rueda, F. M., Fink, G. A., & ten Hompel, M. (2019). Human activity recognition for production and logistics-a systematic literature review. In *Information (Switzerland)* (Vol. 10, Issue 8). MDPI AG. <https://doi.org/10.3390/info10080245>
- [9]. Gilbert, T. J. (2021). Constructing a reference standard for sports science and clinical movement sets using IMU-based motion capture technology.
- [10]. Soro, A., Brunner, G., Tanner, S., & Wattenhofer, R. (2019). Recognition and repetition counting for complex physical exercises with deep learning. *Sensors (Switzerland)*, 19(3). <https://doi.org/10.3390/s19030714>
- [11]. Bradshaw, E. J., Grech, K., Joseph, C. W. J., Calton, M., & Hume, P. A. (2023). Agreement between force and deceleration measures during backward somersault landings. *Sports Biomechanics*, 22(2), 195–203. <https://doi.org/10.1080/14763141.2020.1743348>
- [12]. Dzaja, D. (2023). Quantitative and qualitative assessment of human movement during exercising using inertial and magnetic sensors Dzaja, Dominik. <https://urn.nsk.hr/urn:nbn:hr:168:903772>
- [13]. Abbott, J. C., Wagle, J. P., Sato, K., Painter, K., Light, T. J., & Stone, M. H. (2020). Validation of Inertial Sensor to Measure Barbell Kinematics across a Spectrum of Loading Conditions. *Sports*, 8(7). <https://doi.org/10.3390/sports8070093>
- [14]. Peat, J., & Barton, B. (2005). *Continuous data analyses: correlation and regression*.

Tabla 1. Comparación de los diferentes estudios de la bibliografía en función de sus parámetros más importantes

Referencia*	[1]	[2]	[3]	[4]	[5]	[6]
Número de sensores	1	1	4	1	5	1
Localización de los sensores	Espalda baja	Espalda alta	Espalda alta Espalda baja Tobillo Muñeca	Brazo	Cintura Tobillos Muñecas	Pecho
Frecuencia de muestreo (Hz)	-	100	500	50	100	50
Variables extraídas	Aceleración Vectorial	Aceleración Vectorial	Módulo de aceleración	Aceleración vectorial	Aceleración vectorial	Aceleración vectorial
Método de procesamiento	Estadístico	-	Estadístico (no paramétrico)	Deep Learning	Deep Learning	Deep Learning
Precisión (%)	-	-	90-95	98-99	96-98	92-97

Tabla 2. Continuación

Referencia*	[7]	[9]	[10]	[11]	[12]	[13]
Número de sensores	17	17	1	1	3	1
Localización de los sensores	Cabeza Pecho Muñecas Tobillos Brazos Piernas Espalda	Cabeza Muñecas Tobillos Brazos Piernas Espalda	Muñeca	Espalda alta	Pecho Pierna Muñeca	Externo
Frecuencia de muestreo (Hz)	120	200	100	500	201,03	100
Variables extraídas	Aceleración vectorial	Orientación de Euler	Aceleración vectorial	VPC, VMC VME, VMP, VPE, BW	AVM	EPV EMV MPV CPV CMV
Método de procesamiento	Deep Learning	Estadístico	Deep learning	Estadístico	Estadístico	Estadístico
Precisión (%)	90-95	70-98	99	70	98	80

*[8] y [14] se han excluido de la tabla por ser revisión bibliográfica y referencia matemática sobre análisis estadísticos respectivamente